



Faculdade de Ciências da Universidade do Porto
Departamento de Ciência de Computadores

Data (re)conciliation: Pipelines de Auditoria e Harmonização de Dados Municipais

Relatório Final de Estágio

Autor:

Rodrigo João Bastos Mendes
(up202308366)

Orientador (Empresa):

Eng. Pedro Pimenta (CM Maia)

Regente (FCUP):

Prof. Eduardo Marques

Unidade Curricular: Estágio/Projeto (CC3051) – 2025/2026
Janeiro de 2026

Resumo

A gestão eficiente de uma cidade inteligente depende da qualidade e integridade dos seus dados geoespaciais. Este projeto, desenvolvido no âmbito do grupo D4Maia (Data for Maia), aborda o problema da fragmentação de dados municipais através da criação de processos automáticos de reconciliação de dados (*Data Reconciliation*). O objetivo foi harmonizar a informação oficial da autarquia (WFS) com fontes externas heterogéneas, incluindo OpenStreetMap, dados de transportes (GTFS) e o vasto dataset Overture Maps. Foram desenvolvidas seis *pipelines* de dados em Python, utilizando técnicas de computação em nuvem (Google Colab), processamento de *Big Data* (DuckDB sobre S3) e extração de dados não estruturados (PDF scraping). O resultado é um sistema de auditoria contínua que deteta conflitos de localização e nomenclatura, contribuindo para uma base de dados municipal mais robusta e fiável.

Abstract

The efficient management of a smart city relies on the quality and integrity of its geospatial data. This project, developed within the scope of the D4Maia (Data for Maia) group, addresses the problem of municipal data fragmentation through the development of automated data reconciliation processes. The objective was to harmonize the municipality's official information (WFS) with heterogeneous external sources, including OpenStreetMap, transport data (GTFS), and the vast Overture Maps dataset. Six data pipelines were developed in Python, utilizing cloud computing techniques (Google Colab), Big Data processing (DuckDB over S3), and unstructured data extraction (PDF scraping). The result is a continuous audit system that detects location and naming conflicts, contributing to a more robust and reliable municipal database.

Índice

1. Glossário e Acrónimos	6
2. Introdução	7
2.1. Disponibilização do Código	7
2.2. Enquadramento e Motivação	7
2.3. Objetivos	7
3. Estado da Arte e Tecnologias	8
3.1. Fontes de Dados	8
3.2. Stack Tecnológica	8
4. Metodologia e Evolução do Trabalho	9
4.1. Fase 1: Exploração Inicial e Scripts Simples (Outubro)	9
4.2. Fase 2: Estruturação e Problemas de Ambiente (Novembro)	9
4.3. Fase 3: Refinamento Semântico - Pipeline Escolas (Dezembro)	9
4.4. Fase 4: O Desafio Big Data - Overture Maps (Janeiro)	10
4.5. Fase 5: Pipelines Finais e Dados Não Estruturados	10
4.6. Ferramentas de Apoio e IA	10
4.7. Arquitetura Final	10
5. Implementação e Desafios Técnicos	12
5.1. Algoritmo de Reconciliação	12
5.2. Visualização de Conflitos	12
5.3. Problemas Específicos Resolvidos	13
6. Resultados Obtidos	14
6.1. Análise Detalhada: Mobilidade (Metro e Autocarros)	14
6.2. Análise Detalhada: Equipamentos Escolares	14
6.3. Análise Detalhada: Serviços Sociais (PDF vs Realidade)	15
6.4. Análise Detalhada: Hidrografia e Saúde	15
7. Conclusão	15
Bibliografia	16
8. Apêndices	17
8.1. A. Guia de Leitura dos Relatórios (Data Dictionary)	17
8.2. B. Relatório Detalhado por Caso de Estudo	18
8.2.1. B.1. Pipeline de Mobilidade: Metro do Porto	18
8.2.1.1. 1. Estratégia de Inversão de Fonte	18
8.2.1.2. 2. Análise de Resultados	18
8.2.1.3. 3. Evidência Visual	18
8.2.1.4. 4. Recomendações para a Autarquia	19
8.2.2. B.2. Auditoria à Rede de Autocarros (STCP)	20
8.2.2.1. 1. Contexto	20
8.2.2.2. 2. Análise de Resultados	20
8.2.2.3. 3. Evidência Visual	20
8.2.2.4. 4. Recomendações	21
8.2.3. B.3. Auditoria ao Parque Escolar	22
8.2.3.1. 1. Estratégia de Validação Cruzada	22
8.2.3.2. 2. O Desafio da Normalização	22
8.2.3.3. 3. Análise de Resultados	22
8.2.3.4. 4. Evidência Visual	22
8.2.3.5. 5. Recomendações	23

8.2.4.	B.4. Auditoria aos Serviços Sociais	24
8.2.4.1.	1. Estratégia de Ingestão de Dados Não Estruturados	24
8.2.4.2.	2. Análise de Resultados	24
8.2.4.3.	3. Evidência Visual	24
8.2.4.4.	4. Recomendações Estratégicas	25
8.2.5.	B.5. Auditoria à Hidrografia	26
8.2.5.1.	1. Análise de Cobertura	26
8.2.5.2.	2. Conclusões	26
8.3.	C. Manual de Reprodutibilidade e Extensão	26
8.3.1.	C.1. Pré-requisitos	26
8.3.2.	C.2. Como Executar uma Pipeline	26
8.3.3.	C.3. Como Adaptar a Novos Dados	26
8.4.	D. Links para Recursos do Projeto	26
8.4.1.	Repositório e Notebooks	26
8.4.2.	Relatórios de Resultados (Acesso de Leitura)	27
8.4.3.	Fontes de Dados	27
8.5.	E. Diagrama de Arquitetura (Código)	27

Índice de Figuras

Figura 1	Arquitetura das Pipelines de Reconciliação: Desde a ingestão multifonte até à geração de relatórios (Gerado via Mermaid.ai; Código fonte disponível no Anexo C).	11
Figura 2	Visualização de um “Match Perfeito” no mapa interativo. O popup detalha as distâncias para cada fonte de dados (OSM, Overture, GesEdu) em relação ao ponto oficial (WFS).	12
Figura 3	Visualização de um “Conflito de Localização” no mapa interativo. O mapa desenha uma linha tracejada entre a localização oficial (WFS) e a localização encontrada nas fontes externas (OSM, Overture, GesEdu).	13
Figura 4	Exemplo da tabela detalhada gerada no Google Sheets, pronta para ser entregue aos técnicos da CMM para validação das discrepâncias.	15
Figura 5	Visualização do desvio de 128m na Estação Botica.	19
Figura 6	Exemplo de visualização de paragens com desvio superior a 30 metros.	20
Figura 7	Visualização do desvio de localização na EB de Monte Calvário.	23
Figura 8	Discrepância entre a morada do Guia PDF e a coordenada WFS.	25

Índice de Tabelas

Tabela 1	Resumo quantitativo da auditoria de dados (Valores reais das execuções de Janeiro de 2026).	14
Tabela 2	Dicionário de dados para interpretação das folhas de cálculo geradas.	17
Tabela 3	Tabela de discrepâncias identificadas na rede de Metro.	18
Tabela 4	Paragens com maiores desvios posicionais detetados.	20
Tabela 5	Principais inconsistências detetadas no parque escolar.	22
Tabela 6	Comparação entre o cadastro oficial e as fontes externas/documentais.	24

1. Glossário e Acrónimos

As seguintes abreviaturas e acrónimos são utilizados ao longo deste relatório:

API	Application Programming Interface
AWS	Amazon Web Services
CMM	Câmara Municipal da Maia
D4Maia	Data for Maia (Grupo de trabalho de dados da autarquia)
GesEdu	Plataforma de Gestão Educativa (Fonte Municipal)
GTFS	General Transit Feed Specification
JSON	JavaScript Object Notation
OGC	Open Geospatial Consortium
OSM	OpenStreetMap
PDF	Portable Document Format
STCP	Sociedade de Transportes Colectivos do Porto
VGI	Volunteered Geographic Information
WFS	Web Feature Service (Protocolo padrão OGC)

2. Introdução

No contexto das *Smart Cities*, a capacidade de integrar dados de múltiplas fontes é crucial para a tomada de decisão informada. A Câmara Municipal da Maia (CMM), através do projeto D4Maia, gere um *Data Lake* com diversas camadas de informação. Contudo, existe um desafio persistente: a discrepância entre os dados oficiais mantidos pela autarquia e a realidade observada em plataformas globais e parceiros externos.

Este relatório descreve o projeto de estágio “Data (re)conciliation”, cujo foco foi o desenvolvimento de mecanismos automatizados para cruzar, validar e harmonizar dados de diferentes proveniências.

2.1. Disponibilização do Código

O software e as **pipelines** desenvolvidos no âmbito deste trabalho foram disponibilizados em formato **open-source** num repositório público, com a devida autorização da entidade de acolhimento. O código, instruções de uso e a licença aplicável (MIT) podem ser consultados em:

<https://github.com/RodrigoMendes04/PI2025-DataHarmonization>

2.2. Enquadramento e Motivação

Atualmente, a CMM possui dados oficiais alojados no seu GeoServer (servidos via protocolo WFS) [1], mas estes dados coexistem com informações no OpenStreetMap (OSM), dados de operadores de transporte (Metro do Porto, STCP) e novas bases de dados globais como a Overture Maps. A falta de sincronização gera problemas de:

- **Inconsistência Semântica:** Nomes de escolas ou serviços divergem entre plataformas. Por exemplo, a fonte municipal GesEdu refere “Escola Básica do 1.º Ciclo de Gueifães”, enquanto o OSM pode apresentar a abreviatura “EB1/JI N.º2 de Gueifães”.
- **Imprecisão Geográfica:** A localização de uma paragem de autocarro pode variar dezenas de metros entre o cadastro oficial da autarquia (WFS), o operador de transportes (GTFS) e o mapa público (OpenStreetMap).
- **Dados em Falta (Missing Data):** Identificação de equipamentos que existem no terreno (validados no OSM por cidadãos) mas não constam na base oficial, e vice-versa.

2.3. Objetivos

O objetivo principal foi criar um conjunto de ferramentas (*pipelines*) que executem periodicamente a reconciliação destas fontes. Os objetivos específicos incluíram:

1. **Ingestão Multifonte:** Capacidade de ler APIs WFS/Overpass, ficheiros GTFS, Parquet (Big Data) e documentos PDF (dados não estruturados).
2. **Algoritmos de Matching:** Desenvolvimento de lógica para associar entidades baseada em proximidade espacial e similaridade semântica.
3. **Visualização de Conflitos:** Criação de mapas intuitivos que destaquem visualmente as discrepâncias para correção humana.

3. Estado da Arte e Tecnologias

A reconciliação de dados espaciais é uma área ativa de investigação, focada em resolver a heterogeneidade semântica e posicional [2].

3.1. Fontes de Dados

As fontes utilizadas neste trabalho dividem-se em quatro categorias:

- **GeoServer WFS (Dados Oficiais):** Fonte oficial da CMM, servindo dados vetoriais canónicos via protocolo standard OGC [1].
- **OpenStreetMap (Plataforma Global):** Dados gerados por voluntários (VGI). Embora extensa, a qualidade varia regionalmente [3]. (API Overpass: <https://overpass-api.de/>)
- **Overture Maps (Plataforma Global):** Iniciativa da Linux Foundation (Meta, Microsoft, Amazon). O acesso a estes dados (alojados na AWS S3 em formato Parquet) representou um desafio de *Big Data* [4]. (S3: `s3://overturemaps-us-west-2/`)
- **GTFS (Parceiros Externos):** Especificação utilizada pela STCP e Metro do Porto para definir a rede de transportes.
- **Documentos Não Estruturados:** No domínio social, a fonte primária é o “Guia de Recursos Sociais do Município da Maia” [5], disponibilizado em PDF no portal da autarquia. A fonte educativa GesEdu foi consultada via portal web (<https://www.gesedu.pt/PesquisaRede>).

3.2. Stack Tecnológica

O projeto foi desenvolvido em **Python** no ambiente **Google Colab**. A escolha destas ferramentas deveu-se à sua flexibilidade e vasto ecossistema [6]:

- **GeoPandas & Shapely:** Para manipulação vetorial e operações geométricas.
- **DuckDB:** Motor SQL OLAP utilizado para consultar ficheiros Parquet remotos (S3) sem necessidade de download integral.
- **FuzzyWuzzy:** Implementação da distância de Levenshtein para comparação de strings [7].
- **Folium:** Geração de mapas interativos HTML.

4. Metodologia e Evolução do Trabalho

O desenvolvimento deste projeto seguiu uma abordagem iterativa e incremental, documentada diariamente no **Logbook** do estágio. As soluções técnicas evoluíram à medida que novos desafios — desde problemas de codificação simples até questões de **Big Data** — foram surgindo.

4.1. Fase 1: Exploração Inicial e Scripts Simples (Outubro)

No início do estágio, o foco foi a exploração das APIs. As primeiras tentativas de extração de dados do OpenStreetMap utilizaram scripts simples com a biblioteca `requests` no notebook experimental OSM - `Maia.ipynb`.

A principal dificuldade encontrada nesta fase foi a inconsistência na extração de dados através da API Overpass, que frequentemente falhava por **timeout** ou retornava dados incompletos. Além disso, a comparação de nomes era rudimentar (apenas igualdade exata), o que resultava em poucos **matches**.

4.2. Fase 2: Estruturação e Problemas de Ambiente (Novembro)

Durante o mês de Novembro, o trabalho evoluiu para a criação de **pipelines** estruturadas no Google Colab. Um problema técnico recorrente foi a montagem do Google Drive para guardar os ficheiros intermédios, que falhava se a diretoria já estivesse “montada” ou se a sessão tivesse expirado. A solução passou por implementar uma lógica de limpeza antes da montagem:

```
# Solução para robustez do ambiente Colab
try:
    drive.mount('/content/drive')
except:
    print("Aviso: Drive já montado ou erro. A tentar remontar...")
    drive.flush_and_unmount()
    drive.mount('/content/drive')
```

Listagem 1: Código para garantir a montagem robusta do Google Drive.

Nesta fase, finalizou-se a primeira pipeline robusta: Metro do Porto. Foi implementada a lógica de comparação espacial (distância geodésica) e a geração de mapas interativos com Folium.

4.3. Fase 3: Refinamento Semântico - Pipeline Escolas (Dezembro)

Ao abordar o domínio das Escolas (WFS vs OSM), surgiu uma dificuldade significativa: a disparidade nos nomes. A fonte oficial (WFS/GesEdu) usa nomes formais (“Escola Básica do 1.º Ciclo de...”), enquanto o OSM usa abreviaturas. Para melhorar a taxa de correspondência, foi implementada uma lista de **STOP_WORDS** e normalização de texto para o algoritmo de **Fuzzy Matching**:

```
STOP_WORDS = set(['de', 'da', 'do', 'das', 'dos', 'e', 'o', 'a',
                  'em', 'na', 'no', 'univ', 'universidade',
                  'escola', 'instituto', 'politecnico', 'campus'])

def normalize_text(text):
    # Remoção de acentos e stop words para comparação mais justa
    text = unicode(str(text)).lower().strip()
    # Lógica de remoção de stop words...
    return text
```

Listagem 2: Refinamento do algoritmo de matching com normalização de texto.

Esta alteração permitiu validar automaticamente escolas que antes eram classificadas como conflitos devido a pequenas diferenças na nomenclatura.

4.4. Fase 4: O Desafio Big Data - Overture Maps (Janeiro)

A etapa mais complexa foi a integração do dataset Overture Maps. A tentativa inicial de carregar o ficheiro global causou o **crash** do ambiente Colab por falta de memória RAM. A solução técnica, investigada e implementada, foi a utilização do DuckDB com a extensão **httpfs**. Esta abordagem permitiu executar consultas SQL diretamente sobre os ficheiros Parquet alojados na Cloud (AWS S3), filtrando apenas a área da Maia antes do download.

```
def load_overture_pcp(poly_geom):
    conn = duckdb.connect()
    conn.execute("INSTALL httpfs; LOAD httpfs;")

    # Query direta ao S3 sem download total do dataset
    query = f"""
    SELECT names.primary AS Name, ST_AsWKB(geometry) AS geometry
    FROM read_parquet('s3://overturemaps-us-west-2/release/.../*')
    WHERE bbox.xmin BETWEEN {minx} AND {maxx} ...
    """
    return conn.execute(query).fetchdf()
```

Listagem 3: Consulta SQL direta ao S3 com DuckDB para evitar estouro de memória.

4.5. Fase 5: Pipelines Finais e Dados Não Estruturados

Em Janeiro, foram consolidadas as pipelines finais. Destaca-se o trabalho com os Serviços Sociais, onde a fonte oficial era um PDF. Foi desenvolvido um módulo de **scraping** para extrair moradas e nomes do documento, convertendo dados não estruturados em informação geoespacial comparável.

4.6. Ferramentas de Apoio e IA

No desenvolvimento do código, recorreu-se ao modelo de linguagem Google Gemini como auxiliar de programação.

- **Utilização:** A ferramenta foi preponderante na depuração (*debugging*) de erros complexos e na sugestão de otimizações para as **queries** SQL do DuckDB.
- **Diagramas:** Os fluxogramas da arquitetura (Fig. 1) foram gerados através da ferramenta Mermaid.ai.

4.7. Arquitetura Final

A Figura abaixo ilustra o fluxo de dados consolidado nas 6 pipelines finais.




Figura 1: Arquitetura das Pipelines de Reconciliação: Desde a ingestão multifonte até à geração de relatórios (Gerado via Mermaid.ai; Código fonte disponível no Anexo C).

5. Implementação e Desafios Técnicos

Foram finalizadas seis pipelines: Metro, Autocarros, Escolas, Saúde, Serviços Sociais e Hidrografia.

5.1. Algoritmo de Reconciliação

O núcleo do sistema utiliza uma abordagem híbrida [8]:

1. **Filtro Espacial:** Seleção de candidatos num raio de 50 a 100 metros (Fórmula de Haversine [9]).
2. **Comparação Semântica:** Cálculo do *Token Set Ratio* entre os nomes normalizados.
3. **Classificação:**
 - **Match Perfeito:** Distância < 30m e Nome > 85%.
 - **Conflito de Localização:** Nome igual, mas distância > 30m.
 - **Conflito de Nome:** Localização igual, mas nomes divergentes.

5.2. Visualização de Conflitos

Para facilitar a análise humana, os mapas gerados desenham uma **linha tracejada** entre a localização oficial e a localização encontrada nas fontes externas.



Figura 2: Visualização de um “Match Perfeito” no mapa interativo. O popup detalha as distâncias para cada fonte de dados (OSM, Overture, GesEdu) em relação ao ponto oficial (WFS).




Figura 3: Visualização de um “Conflito de Localização” no mapa interativo. O mapa desenha uma linha tracejada entre a localização oficial (WFS) e a localização encontrada nas fontes externas (OSM, Overture, GesEdu).

5.3. Problemas Específicos Resolvidos

- **Segurança GTFS (Erro 403):** O servidor do Metro do Porto bloqueava os pedidos do Colab. Implementou-se um **fallback** que verifica se existe uma cópia local do ficheiro ZIP no Google Drive antes de tentar o download.
- **Autocarros no Overture:** Verificou-se que o dataset Overture ainda não possui paragens de autocarro da STCP. A pipeline foi adaptada para ignorar esta fonte e evitar falsos negativos.
- **Duplicação de Entidades:** Algumas fontes (WFS Saúde) misturavam Farmácias com Clínicas. Implementou-se uma filtragem prévia por categorias para evitar matches errados.

6. Resultados Obtidos

Esta secção detalha os resultados da auditoria realizada aos dados municipais. A tabela resumo apresenta a visão global (com dados reais extraídos das folhas de cálculo geradas a 21 e 22 de Janeiro), seguida de uma análise detalhada por domínio.

Tabela 1: Resumo quantitativo da auditoria de dados (Valores reais das execuções de Janeiro de 2026).

Pipeline	Entidade Principal	Entidades Externas	Matches Perfeitos	Conflitos / Matches Parciais	Apenas na Fonte Principal
Metro	12 (OSM)	GTFS, WFS e OV	4	8	0
Autocarros	338 (GTFS)	OSM	308	27	3
Escolas	89 (WFS)	OSM, GesEdu e OV	4	76	9
Saúde	35 (WFS)	OSM e OV	14	15	6
Serviços Sociais	240 (WFS)	OSM, PDF e OV	4	175	61
Hidrografia	878 (WFS)	OSM	86	348	444

6.1. Análise Detalhada: Mobilidade (Metro e Autocarros)

A análise da rede de Metro revelou uma elevada consistência posicional. Contudo, foram detetados conflitos de localização em estações chave. Por exemplo, a estação **“Botica”** apresenta um desvio de **128 metros** entre a base oficial (WFS) e as fontes externas, e a estação **“Castêlo da Maia”** um desvio superior a 500 metros no dataset Overture, indicando erros graves na fonte global.

Na rede de Autocarros (STCP), apesar de 340 paragens estarem validadas (“Match Confirmado”), existem casos críticos como a paragem **“Zona Industrial”** (ID ZIND4) com um erro de localização de **61 metros** e a paragem **“Guarda”** (ID GU2) com **43 metros** de desvio.

6.2. Análise Detalhada: Equipamentos Escolares

Este domínio apresentou os maiores desafios semânticos. Ao cruzar os dados do GesEdu (fonte interna) com fontes externas, verificaram-se discrepâncias notáveis:

- **Conflito de Localização:** O **“Jardim de Infância de Moutidos”** foi localizado no OpenStreetMap a **137 metros** de distância da coordenada oficial do GesEdu.
- **Conflito de Nomes:** O **“Colégio de Gueifães”** (WFS) aparece no Overture Maps como **“Colégio CCG”**, obrigando o algoritmo fuzzy a ser calibrado para aceitar acrónimos.

6.3. Análise Detalhada: Serviços Sociais (PDF vs Realidade)

A digitalização do “Guia de Recursos Sociais” revelou lacunas significativas na presença digital das instituições. De um total de 115 entidades extraídas do PDF, a grande maioria (87) resultou em conflito ou não foi encontrada.

- **Discrepância Crítica:** O “Centro Comunitário do Sobreiro” apresentou um desvio de **692 metros** no PDF em relação ao cadastro existente.
- A “Junta de Freguesia da Cidade da Maia” apresentou um desvio superior a **580 metros** entre a morada do PDF e o ponto no Overture Maps.

6.4. Análise Detalhada: Hidrografia e Saúde

Na análise das linhas de água, o pipeline validou cursos como a “Ribeira do Arquinho” com elevada precisão, mas identificou que a “Ribeira do Leandro” está largamente ausente (“Apenas no WFS”) no OpenStreetMap. Na Saúde, destacam-se conflitos de localização em unidades como a “USF Alto da Maia” (desvio de 150m no Overture Maps).

Nome_Oficial_WFS	Lat_Oficial	Lon_Oficial	Nome_OSM	Dist_OSM	Lat_OSM	Lon_OSM	Nome_OV	Dist_OV	Lat_OV	Lon_OV	Status_Key	Status_Label	Comentarios
Unidade de Saúde Familiar Alto da Maia	41.2128769559	-8.5729015307	N/A	-			USF Alto da Maia	150.66	41.2119087	-8.5716413	ConflitoLoc	Conflito Localização (>30m)	[OV] Desvio: 150m
Esferossidade Maia	41.2227633833	-8.61504144736	N/A	-			N/A	-			Apenas	Apenas no WFS	
Unidade de Saúde de Moreira	41.2475946528	-8.66361951016	N/A	-			N/A	-			Apenas	Apenas no WFS	
Cruz Vermelha da Maia	41.2319566137	-8.61537208915	N/A	-			N/A	-			Apenas	Apenas no WFS	
Farmácia do Aeroporto	41.2386812555	-8.67081328996	N/A	-			N/A	-			Apenas	Apenas no WFS	
Farmácia Gramaxo	41.2476707639	-8.66032918153	Farmácia Grami	6.00	41.2476174	-8.6603182	Farmácia Grami	4.24	41.2476992	-8.6602954	Total	Match Perfeito (3 Fontes)	
Farmácia Vila Nova da Telha	41.2578837839	-8.66364489440	N/A	-			N/A	-			Apenas	Apenas no WFS	
Farmácia Lima Coutinho	41.2352318245	-8.61137238226	Lima Coutinho	10.25	41.2262511	-8.6114922	Farmácia Lima	6.36	41.2252889	-8.6113668	Total	Match Perfeito (3 Fontes)	
Farmácia Central de Catassol	41.2250433700	-8.61552115952	Farmácia Centre	8.63	41.2250589	-8.6154201	Farmácia Centre	9.59	41.225076	-8.615415	Total	Match Perfeito (3 Fontes)	
Farmácia Bastos	41.2182859238	-8.6039468281	Farmácia Bastor	5.17	41.2182427	-8.6035718	Farmácia Bastor	4.61	41.2182445	-8.6035932	Total	Match Perfeito (3 Fontes)	
Farmácia Agra	41.2140724045	-8.5946216807	N/A	-			Farmácia Agra	5.28	41.2140433	-8.5945719	Parcial	Match Parcial (2 Fontes)	
Farmácia Eugénia	41.1858744429	-8.58498396172	N/A	-			Farmácia Eugén	11.18	41.1859376	-8.58488	Parcial	Match Parcial (2 Fontes)	
Farmácia Martins da Costa	41.2041353447	-8.57077948878	Farmácia Martin	1.03	41.204143	-8.5707864	Farmácia Martin	21.24	41.2039489	-8.5707245	Total	Match Perfeito (3 Fontes)	
Farmácia das Guadaluas	41.251397206	-8.6506964898	N/A	-			Farmácia das Gl	10.11	41.2513913	-8.6506162	Parcial	Match Parcial (2 Fontes)	
Farmácia Bom Despacho	41.2331407361	-8.62333342169	Farmácia Bom C	11.77	41.2331115	-8.6234687	Farmácia Bom C	9.00	41.2331738	-8.6234316	Total	Match Perfeito (3 Fontes)	
Farmácia Álvaro Agente	41.2363599598	-8.61503106077	N/A	-			Farmácia Nova	12.78	41.2364349	-8.6159469	Parcial	Match Parcial (2 Fontes)	
Farmácia do Castelo	41.2622990250	-8.61570162615	Farmácia do Cai	2.38	41.2623201	-8.6156968	Farmácia do Cai	6.46	41.2623544260	-8.61572495373	Total	Match Perfeito (3 Fontes)	
Farmácia Aliança	41.2420086534	-8.60858416659	Farmácia Alianc	22.13	41.241915	-8.6088177	Farmácia Alianc	2.12	41.2420274	-8.6085888	Total	Match Perfeito (3 Fontes)	
Farmácia de Silva Escuro	41.2555752168	-8.59139434967	N/A	-			Farmácia de Silh	4.28	41.2555377	-8.5914057	Parcial	Match Parcial (2 Fontes)	
Farmácia Araújo	41.2295046898	-8.58796795717	N/A	-			Farmácia Araújo	8.29	41.2294657	-8.5880524	Parcial	Match Parcial (2 Fontes)	
Farmácia da Maia	41.2063802057	-8.56713561815	Farmácia da Ma	9.30	41.2065185	-8.5670605	Farmácia da Ma	5.35	41.2065441	-8.5671778	Total	Match Perfeito (3 Fontes)	
Farmácia Mendonça	41.2559714982	-8.54610940364	N/A	-			Farmácia Mend	14.97	41.2560524	-8.5463326	Parcial	Match Parcial (2 Fontes)	
Farmácia Vales	41.1863003101	-8.59670419395	Farmácia Vales	18.30	41.1861384	-8.5967432	Farmácia Vales	22.58	41.1861047	-8.5967767	Total	Match Perfeito (3 Fontes)	
Farmácia Sousa Torres	41.2194648510	-8.56091887307	Farmácia Sousa	18.17	41.2196247	-8.5608736	N/A	-			Parcial	Match Parcial (2 Fontes)	
Farmácia Moreira Barros	41.2059003915	-8.59730428403	N/A	-			Farmácia Moreir	63.85	41.205397	-8.596937	ConflitoLoc	Conflito Localização (>30m)	[OV] Desvio: 63m
Farmácia Gemunde	41.2671274813	-8.64331532711	Farmácia Gemu	14.81	41.2670618	-8.6431612	Farmácia Gemu	13.84	41.2670079	-8.6432695	Total	Match Perfeito (3 Fontes)	
Hospital de Dia da Maia	41.2348640991	-8.62315161309	Hospital de Dia	19.04	41.2349136	-8.6233695	Hospital de Dia	144.40	41.2348489	-8.6235973	ConflitoLoc	Conflito Localização (>30m)	[OV] Desvio: 44m
Unidade de Saúde Familiar Saúde em	41.195052218	-8.57880935837	Unidade de Saú	3.28	41.1950332	-8.5788016	USF Saúde em	128.90	41.195002	-8.578654	Total	Match Perfeito (3 Fontes)	
Unidade de Saúde Familiar Odiseia	41.2335686930	-8.6173265636	Unidade Local	1.84	41.2335639	-8.6170116	N/A	-			Parcial	Match Parcial (2 Fontes)	
Unidade de Saúde Familiar Lídador	41.2183186545	-8.60561428919	Unidade de Saú	6.39	41.2182758	-8.6055634	Unidade de Saú	9.35	41.2184019	-8.6056304	Total	Match Perfeito (3 Fontes)	
Serviço de Atendimento a Situações U	41.2331531247	-8.62593602613	N/A	-			SASU Maia	40.13	41.2333593	-8.6263307	ConflitoLoc	Conflito Localização (>30m)	[OV] Desvio: 40m
Unidade de Saúde Nogueira	41.234679390	-8.58659125907	N/A	-			N/A	-			Apenas	Apenas no WFS	
Unidade de Saúde de Milheiros	41.2183137363	-8.58914272812	UCSP Maia - MI	32.54	41.2183351	-8.5887547	Unidade de Saú	26.94	41.2183042	-8.5888209	ConflitoLoc	Conflito Localização (>30m)	[OSM] Desvio: 32m

Figura 4: Exemplo da tabela detalhada gerada no Google Sheets, pronta para ser entregue aos técnicos da CMM para validação das discrepâncias.

7. Conclusão

O estágio cumpriu os objetivos propostos, entregando à Câmara Municipal da Maia um conjunto de ferramentas de auditoria de dados robustas e modernas. A evolução técnica do projeto, desde simples scripts até pipelines de *Big Data* com DuckDB e processamento de linguagem natural (Fuzzy Matching), demonstra a complexidade de manter dados consistentes numa Smart City.

As ferramentas desenvolvidas permitem agora à autarquia identificar proativamente erros nos seus dados (WFS/GesEdu) ou desatualizações nas plataformas públicas (OSM), garantindo uma melhor informação ao cidadão.

Trabalho Futuro: Sugere-se a migração destes notebooks para um orquestrador como o Apache Airflow e a criação de uma interface web simples para que os técnicos possam validar as correções sugeridas (“Human-in-the-loop”).

Bibliografia

- [1] Câmara Municipal da Maia, «GeoServer da Câmara Municipal da Maia». [Em linha]. Disponível em: <https://geoserver.cm-maia.pt/geoserver/web/>
- [2] A. Mobasher, A. Zipf, e L. Francis, «Multisource spatial data integration for use cases applications», *Transactions in GIS*, vol. 21, 2017, doi: 10.1111/tgis.12987.
- [3] P. Neis, D. Zielstra, e A. Zipf, «Completeness of OpenStreetMap data: The case of Germany», *ISPRS Int. Journal of Geo-Information*, vol. 1, pp. 6–25, 2011.
- [4] L. Foundation, «Overture Maps Foundation Data Schema». [Em linha]. Disponível em: <https://overturemaps.org/download/>
- [5] Câmara Municipal da Maia, «Guia de Recursos Sociais do Município da Maia». 2025. [Em linha]. Disponível em: https://www.cm-maia.pt/cmniaia/uploads/writer_file/document/13110/guia_de_recursos_sociais_do_municipio_da_maia.pdf
- [6] S. J. Rey, D. Arribas-Bel, e L. J. Wolf, *Geographic Data Science with Python*. CRC Press, 2023. [Em linha]. Disponível em: <https://geographicdata.science/book/>
- [7] V. I. Levenshtein, «Binary codes capable of correcting deletions, insertions, and reversals», *Soviet physics doklady*, vol. 10, pp. 707–710, 1966.
- [8] R. Niranjana, «Proximity Analysis using Python». [Em linha]. Disponível em: <https://medium.com/geekculture/proximity-analysis-using-python-ffd16c457f19>
- [9] N. R. Chopde e M. Nichat, «Landmark based shortest path detection by using A* and Haversine formula», *Int. Journal of Innovative Research in Computer and Communication Engineering*, vol. 1, pp. 298–302, 2013.

8. Apêndices

8.1. A. Guia de Leitura dos Relatórios (Data Dictionary)

Os resultados de cada **pipeline** são exportados para ficheiros Google Sheets (CSV). Para garantir que os **stakeholders** da CMM interpretam corretamente os dados, apresenta-se abaixo o dicionário de dados das colunas geradas.

Tabela 2: Dicionário de dados para interpretação das folhas de cálculo geradas.

Coluna	Descrição
Status / Code	Classificação automática do algoritmo: • Total / Match Perfeito: Correspondência de Nome e Localização (< 30m). • Match Parcial: Correspondência de Nome e Localização (< 30m) entre pelo menos duas fontes de dados mas falta pelo menos uma. • ConflitoLoc: O nome coincide, mas a distância é excessiva. • ConflitoNome: A localização coincide, mas o nome é diferente. • Apenas no ...: A entidade existe na base oficial mas não foi encontrada fora.
Dist_O (O “O” é substituído pela sigla de uma fonte externa)	Distância em metros (geodésica) entre o ponto oficial e a fonte externa.
Comentários	Campo gerado com avisos textuais automáticos (ex: “Mudou de local? Dist: 150m”).
Lat/Lon Oficial	Coordenadas da fonte de verdade (GeoServer CMM ou GTFS).
Lat/Lon Externo	Coordenadas encontradas na fonte auditada.

8.2. B. Relatório Detalhado por Caso de Estudo

Este anexo apresenta os resultados detalhados das auditorias, desenhado para consulta. Cada secção analisa um domínio específico, identifica as fontes de erro e sugere ações de correção.

8.2.1. B.1. Pipeline de Mobilidade: Metro do Porto

Fontes Comparadas: OpenStreetMap (Base) vs. WFS (CMM) vs. GTFS (Operador) vs. Overture.

8.2.1.1. 1. Estratégia de Inversão de Fonte

Ao contrário das outras pipelines, aqui utilizou-se o OpenStreetMap como fonte “pivô” (base de comparação). **Motivo:** O WFS municipal continha apenas um ponto genérico por estação, muitas vezes desatualizado, enquanto o OSM possuía a geometria detalhada das plataformas e entradas. O objetivo foi validar se os dados oficiais (WFS) estavam próximos da realidade física mapeada (OSM).

8.2.1.2. 2. Análise de Resultados

Foram analisadas as **12 estações** mapeadas no OSM dentro do concelho.

- **Cobertura:** Todas as 12 estações do OSM encontraram correspondência no GTFS.
- **Conflitos WFS:** 8 estações no WFS oficial apresentaram desvios significativos (>30m) em relação ao OSM, indicando que o cadastro municipal precisa de ser “arrastado” para a localização real das plataformas.

Tabela 3: Tabela de discrepâncias identificadas na rede de Metro.

Estação (OSM)	Fonte Divergente	Desvio (m)	Diagnóstico
Botica	WFS Oficial	128 m	Erro Crítico no WFS
Aeroporto	Overture	30 m	Desvio Moderado
Castêlo da Maia	Overture	> 500 m	Erro na Fonte Externa (Overture)
Lidador	Todas	< 3 m	Validado (Match Perfeito)

8.2.1.3. 3. Evidência Visual

Abaixo apresenta-se a visualização do conflito na estação “Botica”. A linha tracejada indica a discrepância entre o ponto oficial (WFS) e a estação real (OSM).




Figura 5: Visualização do desvio de 128m na Estação Botica.

8.2.1.4. 4. Recomendações para a Autarquia

1. **Correção Prioritária:** Mover o ponto da estação **Botica** no GeoServer para as coordenadas indicadas pelo OSM/GTFS.
2. **Adoção de Geometrias:** Considerar importar os polígonos das estações do OSM para substituir os pontos simples do WFS, enriquecendo o cadastro municipal.

8.2.2. B.2. Auditoria à Rede de Autocarros (STCP)

Fontes Comparadas: GTFS (STCP Oficial) vs. OpenStreetMap.

8.2.2.1. 1. Contexto

A rede de autocarros é altamente dinâmica, com paragens que mudam de local ou são desativadas frequentemente. A auditoria visou detetar “paragens fantasma” (que existem no mapa mas não na rede atual) e desvios de localização.

8.2.2.2. 2. Análise de Resultados

Do total de **338 paragens** oficiais processadas:

- **308 (91%)** estão corretamente mapeadas no OSM (Distância < 30m).
- **27** apresentam conflitos de localização ou nome.
- **3** paragens presentes no WFS antigo já não constam na rede STCP atual (“Apenas no WFS”).

Top 5 Conflitos de Localização: A tabela abaixo lista as paragens onde o poste físico (OSM) está mais distante da coordenada oficial (GTFS).

Tabela 4: Paragens com maiores desvios posicionais detetados.

ID Paragem	Nome	Desvio (m)	Ação Sugerida
ZIND4	ZONA INDUSTRIAL	61.2 m	Verificar no terreno
GU2	GUARDA	43.5 m	Atualizar WFS
SRA1	SRA. DA HORA	38.1 m	Validar OSM
ALTO1	ALTOS	35.0 m	Validar OSM
MOIT1	MOITINHAS	32.4 m	Baixa Prioridade

8.2.2.3. 3. Evidência Visual

O mapa seguinte ilustra uma zona com alta densidade de paragens onde foram detetadas inconsistências.




Figura 6: Exemplo de visualização de paragens com desvio superior a 30 metros.

8.2.2.4. 4. Recomendações

Recomenda-se a remoção imediata das 3 paragens identificadas como “Apenas no WFS”, pois representam infraestrutura obsoleta que pode confundir os munícipes.

8.2.3. B.3. Auditoria ao Parque Escolar

Fontes Comparadas: WFS (Base Espacial Oficial) vs. GesEdu (Atributos Internos) vs. OpenStreetMap vs. Overture Maps.

8.2.3.1. 1. Estratégia de Validação Cruzada

Neste domínio, a pipeline assumiu o WFS Municipal como a fonte primária de localização. O desafio foi duplo:

1. **Consistência Interna:** Cruzar o WFS com a plataforma GesEdu para garantir que a escola mapeada tem o mesmo nome que a escola gerida administrativamente.
2. **Presença Digital:** Verificar se estas escolas estão corretamente representadas nas plataformas globais (OSM e Overture).

8.2.3.2. 2. O Desafio da Normalização

A principal barreira técnica foi a disparidade semântica entre as fontes:

- **WFS/GesEdu:** Utilizam designações formais e extensas (ex: “Escola Básica do 1.º Ciclo de Gueifães”).
- **OSM/Overture:** Privilegiam acrónimos e nomes de uso comum (ex: “EB1 Gueifães” ou “Escola CCG”).

A solução passou pela implementação de algoritmos de **Fuzzy Matching** com listas de **Stop Words** específicas para o domínio escolar (removendo termos como “Ciclo”, “Ensino”, “Básico”).

8.2.3.3. 3. Análise de Resultados

Foram auditados **89 estabelecimentos de ensino** constantes no WFS.

- **Cobertura:** 9 escolas do WFS não foram encontradas em nenhuma fonte externa (“Apenas no WFS”), indicando uma lacuna na visibilidade pública destes equipamentos.
- **Conflitos:** Identificaram-se 27 casos onde a localização ou o nome divergem significativamente.

Top Discrepâncias Identificadas:

Tabela 5: Principais inconsistências detetadas no parque escolar.

Escola (WFS)	Fonte de Conflito	Desvio / Erro	Diagnóstico
JI de Moutidos	OSM	137 m	WFS no centroide vs OSM na entrada
Colégio de Gueifães	Overture	Nomenclatura	Nome no OV: “Colégio CCG”
EB1/JI de Ferronho	OSM	28 m	Desvio no limite da tolerância
Castelmaia	OSM	Em Falta	Escola ausente no mapa público

8.2.3.4. 4. Evidência Visual

O mapa seguinte destaca o caso da “EB de Monte Calvário”, onde o ponto oficial (WFS) está localizado no meio do terreno, enquanto o ponto do OpenStreetMap marca a entrada do edifício, gerando um falso positivo de conflito de distância (>100m).




Figura 7: Visualização do desvio de localização na EB de Monte Calvário.

8.2.3.5. 5. Recomendações

1. Enriquecimento de Metadados: Adicionar um campo “Nome Alternativo” ou “Sigla” ao WFS/GesEdu. Isto facilitaria a pesquisa por parte dos cidadãos e a interoperabilidade com sistemas externos.
2. Atualização do OSM: A equipa D4Maia deve promover a inserção das 9 escolas em falta no OpenStreetMap, garantindo que pais e alunos encontram a localização correta em aplicações de navegação.

8.2.4. B.4. Auditoria aos Serviços Sociais

Fontes Comparadas: WFS (Base Espacial Oficial) vs. PDF “Guia de Recursos” vs. OpenStreetMap vs. Overture Maps.

8.2.4.1. 1. Estratégia de Ingestão de Dados Não Estruturados

Neste domínio, o WFS Municipal serviu como base de comparação (“Entidade Principal”). O aspeto inovador desta pipeline foi a integração de uma fonte de dados **não estruturada**: o “Guia de Recursos Sociais”, um documento PDF utilizado pelos munícipes. O objetivo foi triplo:

1. Verificar se o WFS contém todas as instituições listadas no PDF.
2. Validar se as moradas descritas no PDF correspondem às coordenadas geográficas do WFS.
3. Avaliar a presença digital destas instituições nas plataformas globais (OSM/Overture).

8.2.4.2. 2. Análise de Resultados

Foram analisadas **240 instituições** registadas no WFS. Os resultados revelaram uma desconexão significativa entre as várias fontes:

- **Matches Perfeitos:** Apenas 4 instituições apresentaram consistência total (Nome e Localização) entre o WFS e as restantes fontes.
- **Conflitos:** 175 registos apresentaram discrepâncias. Grande parte deve-se à dificuldade de geocodificar moradas antigas ou imprecisas extraídas do PDF.
- **Lacunas:** 61 instituições do WFS não foram encontradas em nenhuma fonte externa (“Apenas no WFS”).

Top Discrepâncias Identificadas:

Tabela 6: Comparação entre o cadastro oficial e as fontes externas/documentais.

Instituição (WFS)	Fonte Divergente	Desvio	Diagnóstico
Centro Com. Sobreiro	PDF (Geocoded)	692 m	Morada do PDF imprecisa ou obsoleta
Junta Freg. Cidade Maia	Overture	580 m	Erro de localização na fonte global
Centro Social Guardedeiras	Todas	< 10 m	Validado (Sucesso)
Assoc. Solid. de Vila Nova	OSM	Em Falta	Ausente do mapa público

8.2.4.3. 3. Evidência Visual

O mapa abaixo ilustra um caso de “Conflito de Localização” gerado pela geocodificação do PDF. O ponto extraído do texto do PDF (através da API de geocoding) afasta-se significativamente da localização real do edifício registada no WFS.



Figura 8: Discrepância entre a morada do Guia PDF e a coordenada WFS.

8.2.4.4. 4. Recomendações Estratégicas

1. Digitalização na Origem: Abandonar a manutenção manual do “Guia de Recursos” em Word/PDF. O documento deve ser gerado automaticamente a partir do WFS/Base de Dados, garantindo que a morada impressa corresponde sempre à coordenada oficial.
2. Campanha de Mapeamento: Dada a função social crítica destas instituições (IPSS, Lares, Apoio Domiciliário), recomenda-se uma campanha para inserir as 61 instituições em falta no OpenStreetMap, facilitando o acesso da população a estes serviços.

8.2.5. B.5. Auditoria à Hidrografia

Fontes Comparadas: WFS (Linhas de Água) vs. OpenStreetMap (Waterways).

8.2.5.1. 1. Análise de Cobertura

Ao contrário dos edifícios, a hidrografia analisou a **cobertura** da rede.

- **Rede Oficial (WFS):** 878 segmentos de linha.
- **Rede OSM:** 252 segmentos.

8.2.5.2. 2. Conclusões

Existe uma lacuna massiva de informação no OpenStreetMap (444 segmentos oficiais sem correspondência). Enquanto os grandes cursos de água (**Ribeira do Arquinho, Ribeira do Avioso**) estão bem mapeados e reconciliados, a micro-drenagem e linhas de água secundárias estão ausentes dos mapas públicos.

Ação Recomendada: A CMM, detentora de dados hidrológicos de alta precisão, poderia contribuir para o OpenStreetMap importando os traçados das linhas de água principais em falta, melhorando a utilidade do mapa para proteção civil e ambiente.

8.3. C. Manual de Reprodutibilidade e Extensão

Este guia destina-se a quem pretenda continuar o trabalho ou re-executar as auditorias.

8.3.1. C.1. Pré-requisitos

O projeto foi desenhado para ser executado na nuvem (Google Colab), eliminando a necessidade de instalação local complexa.

1. Conta Google com acesso ao Google Drive.
2. Ficheiros de credenciais (opcional): Configurar “Secrets” no Colab com `GMAIL_USER`, `GMAIL_APP_PASSWORD` e `DRIVE_SAVE_PATH`.

8.3.2. C.2. Como Executar uma Pipeline

1. Aceda ao link do Notebook desejado (ver Anexo D).
2. Clique em “Open in Colab”.
3. No menu superior, selecione **Executar tudo**.
4. O script irá:
 - Instalar automaticamente as bibliotecas (`geopandas`, `folium`, `duckdb`).
 - Pedir autorização para ligar ao Google Drive.
 - Processar os dados e gerar dois ficheiros na pasta `/Colab_Pipelines/`: um Excel com a auditoria e um Mapa HTML.

8.3.3. C.3. Como Adaptar a Novos Dados

Para aplicar esta lógica a um novo domínio:

1. Duplica um dos notebooks.
2. Altere a variável `OFFICIAL_DATA_URL` para o novo **endpoint** WFS do GeoServer.
3. Ajuste a **query** do OpenStreetMap na função `query_osm_data()` para procurar as tags adequadas.
4. Execute o script. A lógica de **matching** espacial e semântica manter-se-á funcional.

8.4. D. Links para Recursos do Projeto

8.4.1. Repositório e Notebooks

Repositório GitHub (Código Fonte):

<https://github.com/RodrigoMendes04/PI2025-DataHarmonization>

Notebooks (Google Colab):

- **Metro:** <https://colab.research.google.com/drive/1Rc1AaOzQSwrWFVJWQzomUrCGvJR Fgbv0>
- **Escolas:** https://colab.research.google.com/drive/1__3f4ehdsPWR4VvbbYKHswYmWWW Th1hbN
- **Social:** <https://colab.research.google.com/drive/1sPljxaxvR1Pw0InJGZKBcuBGRd7 SRUkT>
- **Saúde:** https://colab.research.google.com/drive/10WhQz96-SIWJM2vEG5ji-ew0q_f-ZoRd
- **Autocarros:** <https://colab.research.google.com/drive/1RJObbbVQfazrcErgpMcXdMYDfS 8itqwg>
- **Hidrografia:** <https://colab.research.google.com/drive/1gIuS3VzeZxJndUG8QBLgqZP2p7 gn1hKP>

8.4.2. Relatórios de Resultados (Acesso de Leitura)

- **Metro:** <https://docs.google.com/spreadsheets/d/117rBWevZidc33NpGOHleUssKAQG63 LJBbZfGKm3ocac>
- **Escolas:** https://docs.google.com/spreadsheets/d/1MuL7dj7H1m5g4YovFih_dagAIOwX4 UoSQuWJMee5LKc
- **Serviços Sociais:** <https://docs.google.com/spreadsheets/d/1FkuzSo4WoUqB5iechWalDW noZFfFo-VLrBw9cCEsXbQ>
- **Saúde:** <https://docs.google.com/spreadsheets/d/1Vsu8eSSrsfjM9Hk7fWETqs1NlovwDGsi -rEBKN3fLr0>
- **Autocarros:** https://docs.google.com/spreadsheets/d/1cbbg2NcfwPGyWBqmfMAILyal42 XrKfOPirU_JasOUJo
- **Hidrografia:** <https://docs.google.com/spreadsheets/d/1CsJw8c1aKnbpRBOTRZMYQ0w8 CeJeLQUUp3oU73d-FPk>

8.4.3. Fontes de Dados

- **GesEdu:** <https://www.gesedu.pt/PesquisaRede>
- **OpenStreetMap (Overpass):** <https://overpass-api.de/>
- **Overture Maps:** <https://overturemaps.org/>

8.5. E. Diagrama de Arquitetura (Código)

O diagrama da Figura 1 foi gerado via Mermaid.ai com o seguinte código:

```
---
config:
  layout: dagre
---
graph TD
  classDef fontes fill:#elf5fe,stroke:#01579b,stroke-width:2px,color:black;
  classDef process fill:#e8f5e9,stroke:#2e7d32,stroke-width:2px,color:black;
  classDef output fill:#fff3e0,stroke:#ef6c00,stroke-width:2px,color:black;

  subgraph Sources ["1. Fontes de Dados"]
    direction TB
    WFS["WFS Maia<br/>(Oficial)"]::fontes
    OSM["OpenStreetMap<br/>(API Overpass)"]::fontes
    GTFS["GTFS / PDF<br/>(Ficheiros)"]::fontes
    OV["Overture Maps<br/>(AWS S3 / Parquet)"]::fontes
  end
```

```

end

subgraph Python ["2. Processamento"]
    direction TB
    Ingest["Ingestão & Limpeza<br/>(DuckDB / Pandas)"]:::process
    Norm["Normalização &<br/>Filtragem Espacial"]:::process

    subgraph Logic ["Núcleo de Reconciliação"]
        direction TB
        Dist["Cálculo Distância<br/>(Haversine)"]:::process
        Fuzzy["Comparação Nomes<br/>(Levenshtein)"]:::process
        Class{"Classificação<br/>(Match/Conflito)"}:::process
    end
end

subgraph Results ["3. Outputs"]
    direction TB
    XLS["Relatório<br/>Google Sheets"]:::output
    MAP["Mapa Interativo<br/>Folium HTML"]:::output
    MAIL["Notificação<br/>Email SMTP"]:::output
end

WFS --> Ingest
OSM --> Ingest
GTFS --> Ingest
OV --> Ingest

Ingest --> Norm
Norm --> Dist
Norm --> Fuzzy

Dist --> Class
Fuzzy --> Class

Class --> XLS
Class --> MAP
XLS --> MAIL

```