



Faculdade de Ciências da Universidade do Porto
Departamento de Ciência de Computadores

Data (re)conciliation: Pipelines de Auditoria e Harmonização de Dados Municipais

Relatório Final de Estágio

Autor:

Rodrigo João Bastos Mendes
(up202308366)

Orientador (Empresa):

Eng. Pedro Pimenta (CM Maia)

Regente (FCUP):

Prof. Eduardo Marques

Unidade Curricular: Estágio/Projeto (CC3051) – 2025/2026
Janeiro de 2026

Resumo

A gestão eficiente de uma cidade inteligente depende da qualidade e integridade dos seus dados geoespaciais. Este projeto, desenvolvido no âmbito do grupo D4Maia (Data for Maia), aborda o problema da fragmentação de dados municipais através da criação de processos automáticos de reconciliação de dados (*Data Reconciliation*). O objetivo foi harmonizar a informação oficial da autarquia (WFS) com fontes externas heterogéneas, incluindo OpenStreetMap, dados de transportes (GTFS) e o vasto dataset Overture Maps. Foram desenvolvidas seis *pipelines* de dados em Python, utilizando técnicas de computação em nuvem (Google Colab), processamento de *Big Data* (DuckDB sobre S3) e extração de dados não estruturados (PDF scraping). O resultado é um sistema de auditoria contínua que deteta conflitos de localização e nomenclatura, contribuindo para uma base de dados municipal mais robusta e fiável.

Índice

1. Glossário e Acrónimos	5
2. Introdução	6
2.1. Disponibilização do Código	6
2.2. Enquadramento e Motivação	6
2.3. Objetivos	6
3. Estado da Arte e Tecnologias	7
3.1. Fontes de Dados	7
3.2. Stack Tecnológica	7
4. Metodologia e Evolução do Trabalho	8
4.1. Fase 1: Exploração Inicial e Scripts Simples (Outubro)	8
4.2. Fase 2: Estruturação e Problemas de Ambiente (Novembro)	8
4.3. Fase 3: Refinamento Semântico - Pipeline Escolas (Dezembro)	8
4.4. Fase 4: O Desafio Big Data - Overture Maps (Janeiro)	9
4.5. Fase 5: Pipelines Finais e Dados Não Estruturados	9
4.6. Ferramentas de Apoio e IA	9
4.7. Arquitetura Final	9
5. Implementação e Desafios Técnicos	11
5.1. Algoritmo de Reconciliação	11
5.2. Visualização de Conflitos	11
5.3. Problemas Específicos Resolvidos	12
6. Resultados Obtidos	13
6.1. Análise Detalhada: Mobilidade (Metro e Autocarros)	13
6.2. Análise Detalhada: Equipamentos Escolares	13
6.3. Análise Detalhada: Serviços Sociais (PDF vs Realidade)	14
6.4. Análise Detalhada: Hidrografia e Saúde	14
7. Conclusão	15
Bibliografia	15
8. Apêndices	16
8.1. A. Repositório, Notebooks e Dados	16
8.1.1. Código Fonte	16
8.1.2. Pipelines de Processamento (Google Colab)	16
8.1.3. Relatórios de Resultados (Google Sheets)	16
8.1.4. Fontes de Dados Externas	16
8.2. B. Scripts e Soluções Técnicas	16
8.2.1. B.1 Tratamento de Erro de Segurança (GTFS Error 403)	16
8.2.2. B.2 Código do Diagrama de Arquitetura	17

Índice de Figuras

Figura 1	Arquitetura das Pipelines de Reconciliação: Desde a ingestão multifonte até à geração de relatórios (Gerado via Mermaid.ai; Código fonte disponível no Anexo C).	10
Figura 2	Visualização de um “Match Perfeito” no mapa interativo. O popup detalha as distâncias para cada fonte de dados (OSM, Overture, GesEdu) em relação ao ponto oficial (WFS).	11
Figura 3	Visualização de um “Conflito de Localização” no mapa interativo. O mapa desenha uma linha tracejada entre a localização oficial (WFS) e a localização encontrada nas fontes externas (OSM, Overture, GesEdu).	12
Figura 4	Exemplo da tabela detalhada gerada no Google Sheets, pronta para ser entregue aos técnicos da CMM para validação das discrepâncias.	14

Índice de Tabelas

Tabela 1	Resumo quantitativo da auditoria de dados (Valores reais das execuções de Janeiro de 2026).	13
----------	---	----

1. Glossário e Acrónimos

As seguintes abreviaturas e acrónimos são utilizados ao longo deste relatório:

API	Application Programming Interface
AWS	Amazon Web Services
CMM	Câmara Municipal da Maia
D4Maia	Data for Maia (Grupo de trabalho de dados da autarquia)
GesEdu	Plataforma de Gestão Educativa (Fonte Municipal)
GTFS	General Transit Feed Specification
JSON	JavaScript Object Notation
OGC	Open Geospatial Consortium
OSM	OpenStreetMap
PDF	Portable Document Format
STCP	Sociedade de Transportes Colectivos do Porto
VGI	Volunteered Geographic Information
WFS	Web Feature Service (Protocolo padrão OGC)

2. Introdução

No contexto das *Smart Cities*, a capacidade de integrar dados de múltiplas fontes é crucial para a tomada de decisão informada. A Câmara Municipal da Maia (CMM), através do projeto D4Maia, gere um *Data Lake* com diversas camadas de informação. Contudo, existe um desafio persistente: a discrepância entre os dados oficiais mantidos pela autarquia e a realidade observada em plataformas globais e parceiros externos.

Este relatório descreve o projeto de estágio “Data (re)conciliation”, cujo foco foi o desenvolvimento de mecanismos automatizados para cruzar, validar e harmonizar dados de diferentes proveniências.

2.1. Disponibilização do Código

O software e as **pipelines** desenvolvidos no âmbito deste trabalho foram disponibilizados em formato **open-source** num repositório público, com a devida autorização da entidade de acolhimento. O código, instruções de uso e a licença aplicável (MIT) podem ser consultados em:

<https://github.com/RodrigoMendes04/PI2025-DataHarmonization>

2.2. Enquadramento e Motivação

Atualmente, a CMM possui dados oficiais alojados no seu GeoServer (servidos via protocolo WFS) [1], mas estes dados coexistem com informações no OpenStreetMap (OSM), dados de operadores de transporte (Metro do Porto, STCP) e novas bases de dados globais como a Overture Maps. A falta de sincronização gera problemas de:

- **Inconsistência Semântica:** Nomes de escolas ou serviços divergem entre plataformas. Por exemplo, a fonte municipal GesEdu refere “Escola Básica do 1.º Ciclo de Gueifães”, enquanto o OSM pode apresentar a abreviatura “EB1/JI N.º2 de Gueifães”.
- **Imprecisão Geográfica:** A localização de uma paragem de autocarro pode variar dezenas de metros entre o cadastro oficial da autarquia (WFS), o operador de transportes (GTFS) e o mapa público (OpenStreetMap).
- **Dados em Falta (Missing Data):** Identificação de equipamentos que existem no terreno (validados no OSM por cidadãos) mas não constam na base oficial, e vice-versa.

2.3. Objetivos

O objetivo principal foi criar um conjunto de ferramentas (*pipelines*) que executem periodicamente a reconciliação destas fontes. Os objetivos específicos incluíram:

1. **Ingestão Multifonte:** Capacidade de ler APIs WFS/Overpass, ficheiros GTFS, Parquet (Big Data) e documentos PDF (dados não estruturados).
2. **Algoritmos de Matching:** Desenvolvimento de lógica para associar entidades baseada em proximidade espacial e similaridade semântica.
3. **Visualização de Conflitos:** Criação de mapas intuitivos que destaquem visualmente as discrepâncias para correção humana.

3. Estado da Arte e Tecnologias

A reconciliação de dados espaciais é uma área ativa de investigação, focada em resolver a heterogeneidade semântica e posicional [2].

3.1. Fontes de Dados

As fontes utilizadas neste trabalho dividem-se em quatro categorias:

- **GeoServer WFS (Dados Oficiais):** Fonte oficial da CMM, servindo dados vetoriais canónicos via protocolo standard OGC [1].
- **OpenStreetMap (Plataforma Global):** Dados gerados por voluntários (VGI). Embora extensa, a qualidade varia regionalmente [3]. (API Overpass: <https://overpass-api.de/>)
- **Overture Maps (Plataforma Global):** Iniciativa da Linux Foundation (Meta, Microsoft, Amazon). O acesso a estes dados (alojados na AWS S3 em formato Parquet) representou um desafio de *Big Data* [4]. (S3: `s3://overturemaps-us-west-2/`)
- **GTFS (Parceiros Externos):** Especificação utilizada pela STCP e Metro do Porto para definir a rede de transportes.
- **Documentos Não Estruturados:** No domínio social, a fonte primária é o “Guia de Recursos Sociais do Município da Maia” [5], disponibilizado em PDF no portal da autarquia. A fonte educativa GesEdu foi consultada via portal web (<https://www.gesedu.pt/PesquisaRede>).

3.2. Stack Tecnológica

O projeto foi desenvolvido em **Python** no ambiente **Google Colab**. A escolha destas ferramentas deveu-se à sua flexibilidade e vasto ecossistema [6]:

- **GeoPandas & Shapely:** Para manipulação vetorial e operações geométricas.
- **DuckDB:** Motor SQL OLAP utilizado para consultar ficheiros Parquet remotos (S3) sem necessidade de download integral.
- **FuzzyWuzzy:** Implementação da distância de Levenshtein para comparação de strings [7].
- **Folium:** Geração de mapas interativos HTML.

4. Metodologia e Evolução do Trabalho

O desenvolvimento deste projeto seguiu uma abordagem iterativa e incremental, documentada diariamente no **Logbook** do estágio. As soluções técnicas evoluíram à medida que novos desafios — desde problemas de codificação simples até questões de **Big Data** — foram surgindo.

4.1. Fase 1: Exploração Inicial e Scripts Simples (Outubro)

No início do estágio, o foco foi a exploração das APIs. As primeiras tentativas de extração de dados do OpenStreetMap utilizaram scripts simples com a biblioteca `requests` no notebook experimental OSM - `Maia.ipynb`.

A principal dificuldade encontrada nesta fase foi a inconsistência na extração de dados através da API Overpass, que frequentemente falhava por **timeout** ou retornava dados incompletos. Além disso, a comparação de nomes era rudimentar (apenas igualdade exata), o que resultava em poucos **matches**.

4.2. Fase 2: Estruturação e Problemas de Ambiente (Novembro)

Durante o mês de Novembro, o trabalho evoluiu para a criação de **pipelines** estruturadas no Google Colab. Um problema técnico recorrente foi a montagem do Google Drive para guardar os ficheiros intermédios, que falhava se a diretoria já estivesse “montada” ou se a sessão tivesse expirado. A solução passou por implementar uma lógica de limpeza antes da montagem:

```
# Solução para robustez do ambiente Colab
try:
    drive.mount('/content/drive')
except:
    print("Aviso: Drive já montado ou erro. A tentar remontar...")
    drive.flush_and_unmount()
    drive.mount('/content/drive')
```

Listagem 1: Código para garantir a montagem robusta do Google Drive.

Nesta fase, finalizou-se a primeira pipeline robusta: Metro do Porto. Foi implementada a lógica de comparação espacial (distância geodésica) e a geração de mapas interativos com Folium.

4.3. Fase 3: Refinamento Semântico - Pipeline Escolas (Dezembro)

Ao abordar o domínio das Escolas (WFS vs OSM), surgiu uma dificuldade significativa: a disparidade nos nomes. A fonte oficial (WFS/GesEdu) usa nomes formais (“Escola Básica do 1.º Ciclo de...”), enquanto o OSM usa abreviaturas. Para melhorar a taxa de correspondência, foi implementada uma lista de **STOP_WORDS** e normalização de texto para o algoritmo de **Fuzzy Matching**:

```
STOP_WORDS = set(['de', 'da', 'do', 'das', 'dos', 'e', 'o', 'a',
                  'em', 'na', 'no', 'univ', 'universidade',
                  'escola', 'instituto', 'politecnico', 'campus'])

def normalize_text(text):
    # Remoção de acentos e stop words para comparação mais justa
    text = unicode(str(text)).lower().strip()
    # Lógica de remoção de stop words...
    return text
```

Listagem 2: Refinamento do algoritmo de matching com normalização de texto.

Esta alteração permitiu validar automaticamente escolas que antes eram classificadas como conflitos devido a pequenas diferenças na nomenclatura.

4.4. Fase 4: O Desafio Big Data - Overture Maps (Janeiro)

A etapa mais complexa foi a integração do dataset Overture Maps. A tentativa inicial de carregar o ficheiro global causou o **crash** do ambiente Colab por falta de memória RAM. A solução técnica, investigada e implementada, foi a utilização do DuckDB com a extensão **httpfs**. Esta abordagem permitiu executar consultas SQL diretamente sobre os ficheiros Parquet alojados na Cloud (AWS S3), filtrando apenas a área da Maia antes do download.

```
def load_overture_pcp(poly_geom):
    conn = duckdb.connect()
    conn.execute("INSTALL httpfs; LOAD httpfs;")

    # Query direta ao S3 sem download total do dataset
    query = f"""
    SELECT names.primary AS Name, ST_AsWKB(geometry) AS geometry
    FROM read_parquet('s3://overturemaps-us-west-2/release/.../*')
    WHERE bbox.xmin BETWEEN {minx} AND {maxx} ...
    """
    return conn.execute(query).fetchdf()
```

Listagem 3: Consulta SQL direta ao S3 com DuckDB para evitar estouro de memória.

4.5. Fase 5: Pipelines Finais e Dados Não Estruturados

Em Janeiro, foram consolidadas as pipelines finais. Destaca-se o trabalho com os Serviços Sociais, onde a fonte oficial era um PDF. Foi desenvolvido um módulo de **scraping** para extrair moradas e nomes do documento, convertendo dados não estruturados em informação geoespacial comparável.

4.6. Ferramentas de Apoio e IA

No desenvolvimento do código, recorreu-se ao modelo de linguagem Google Gemini como auxiliar de programação.

- **Utilização:** A ferramenta foi preponderante na depuração (*debugging*) de erros complexos e na sugestão de otimizações para as **queries** SQL do DuckDB.
- **Diagramas:** Os fluxogramas da arquitetura (Fig. 1) foram gerados através da ferramenta Mermaid.ai.

4.7. Arquitetura Final

A Figura abaixo ilustra o fluxo de dados consolidado nas 6 pipelines finais.




Figura 1: Arquitetura das Pipelines de Reconciliação: Desde a ingestão multifonte até à geração de relatórios (Gerado via Mermaid.ai; Código fonte disponível no Anexo C).

5. Implementação e Desafios Técnicos

Foram finalizadas seis pipelines: Metro, Autocarros, Escolas, Saúde, Serviços Sociais e Hidrografia.

5.1. Algoritmo de Reconciliação

O núcleo do sistema utiliza uma abordagem híbrida [8]:

1. **Filtro Espacial:** Seleção de candidatos num raio de 50 a 100 metros (Fórmula de Haversine [9]).
2. **Comparação Semântica:** Cálculo do *Token Set Ratio* entre os nomes normalizados.
3. **Classificação:**
 - **Match Perfeito:** Distância < 30m e Nome > 85%.
 - **Conflito de Localização:** Nome igual, mas distância > 30m.
 - **Conflito de Nome:** Localização igual, mas nomes divergentes.

5.2. Visualização de Conflitos

Para facilitar a análise humana, os mapas gerados desenham uma **linha tracejada** entre a localização oficial e a localização encontrada nas fontes externas.



Figura 2: Visualização de um “Match Perfeito” no mapa interativo. O popup detalha as distâncias para cada fonte de dados (OSM, Overture, GesEdu) em relação ao ponto oficial (WFS).




Figura 3: Visualização de um “Conflito de Localização” no mapa interativo. O mapa desenha uma linha tracejada entre a localização oficial (WFS) e a localização encontrada nas fontes externas (OSM, Overture, GesEdu).

5.3. Problemas Específicos Resolvidos

- **Segurança GTFS (Erro 403):** O servidor do Metro do Porto bloqueava os pedidos do Colab. Implementou-se um **fallback** que verifica se existe uma cópia local do ficheiro ZIP no Google Drive antes de tentar o download.
- **Autocarros no Overture:** Verificou-se que o dataset Overture ainda não possui paragens de autocarro da STCP. A pipeline foi adaptada para ignorar esta fonte e evitar falsos negativos.
- **Duplicação de Entidades:** Algumas fontes (WFS Saúde) misturavam Farmácias com Clínicas. Implementou-se uma filtragem prévia por categorias para evitar matches errados.

6. Resultados Obtidos

Esta secção detalha os resultados da auditoria realizada aos dados municipais. A tabela resumo apresenta a visão global (com dados reais extraídos das folhas de cálculo geradas a 21 e 22 de Janeiro), seguida de uma análise detalhada por domínio.

Tabela 1: Resumo quantitativo da auditoria de dados (Valores reais das execuções de Janeiro de 2026).

Pipeline	Fontes Inte- gradadas	Entidades no total	Matches	Conflitos / Apenas na fonte Oficial
Metro	WFS, OSM, GTFS, Over- ture	23	12	11
Autocarros	WFS, GTFS, OSM	452	340	112
Escolas	WFS, OSM, GesEdu, Over- ture	85	52	33
Saúde	WFS, OSM, Overture	56	35	21
Serviços Sociais	WFS, OSM, PDF, Overture	115	28	87
Hidrografia	WFS, OSM	320	180	140

6.1. Análise Detalhada: Mobilidade (Metro e Autocarros)

A análise da rede de Metro revelou uma elevada consistência posicional. Contudo, foram detetados conflitos de localização em estações chave. Por exemplo, a estação **“Botica”** apresenta um desvio de **128 metros** entre a base oficial (WFS) e as fontes externas, e a estação **“Castêlo da Maia”** um desvio superior a 500 metros no dataset Overture, indicando erros graves na fonte global.

Na rede de Autocarros (STCP), apesar de 340 paragens estarem validadas (“Match Confirmado”), existem casos críticos como a paragem **“Zona Industrial”** (ID ZIND4) com um erro de localização de **61 metros** e a paragem **“Guarda”** (ID GU2) com **43 metros** de desvio.

6.2. Análise Detalhada: Equipamentos Escolares

Este domínio apresentou os maiores desafios semânticos. Ao cruzar os dados do GesEdu (fonte interna) com fontes externas, verificaram-se discrepâncias notáveis:

- **Conflito de Localização:** O **“Jardim de Infância de Moutidos”** foi localizado no OpenStreetMap a **137 metros** de distância da coordenada oficial do GesEdu.
- **Conflito de Nomes:** O **“Colégio de Gueifães”** (WFS) aparece no Overture Maps como **“Colégio CCG”**, obrigando o algoritmo fuzzy a ser calibrado para aceitar acrónimos.

6.3. Análise Detalhada: Serviços Sociais (PDF vs Realidade)

A digitalização do “Guia de Recursos Sociais” revelou lacunas significativas na presença digital das instituições. De um total de 115 entidades extraídas do PDF, a grande maioria (87) resultou em conflito ou não foi encontrada.

- **Discrepância Crítica:** O “Centro Comunitário do Sobreiro” apresentou um desvio de **692 metros** no PDF em relação ao cadastro existente.
- A “Junta de Freguesia da Cidade da Maia” apresentou um desvio superior a **580 metros** entre a morada do PDF e o ponto no Overture Maps.

6.4. Análise Detalhada: Hidrografia e Saúde

Na análise das linhas de água, o pipeline validou cursos como a “Ribeira do Arquinho” com elevada precisão, mas identificou que a “Ribeira do Leandro” está largamente ausente (“Apenas no WFS”) no OpenStreetMap. Na Saúde, destacam-se conflitos de localização em unidades como a “USF Alto da Maia” (desvio de 150m no Overture Maps).

Nome_Oficial_WFS	Lat_Oficial	Lon_Oficial	Nome_OSM	Dist_OSM	Lat_OSM	Lon_OSM	Nome_OV	Dist_OV	Lat_OV	Lon_OV	Status_Key	Status_Label	Comentarios
Unidade de Saúde Familiar Alto da Ma	41.2128769599	-8.67290125387	N/A	-			USF Alto da Ma	150.66	41.2119087	-8.5716413	ConflitoLoc	Conflito Localização (>30m)	[OV] Desvio: 150m
Esferasaúde Maia	41.2227034363	-8.61504144736	N/A	-			N/A	-			Apenas	Apenas no WFS	
Unidade de Saúde de Moreira	41.2475946528	-8.66361951816	N/A	-			N/A	-			Apenas	Apenas no WFS	
Cruz Vermelha da Maia	41.2319566137	-8.61537280915	N/A	-			N/A	-			Apenas	Apenas no WFS	
Farmácia do Aeroporto	41.2386812565	-8.67081328996	N/A	-			N/A	-			Apenas	Apenas no WFS	
Farmácia Gramaxo	41.2476707639	-8.6602918153	Farmácia Gramu	6.00	41.2476174	-8.6603182	Farmácia Gramu	4.24	41.2476992	-8.6602954	Total	Match Perfeito (3 Fontes)	
Farmácia Vila Nova da Telha	41.2578837839	-8.66364489440	N/A	-			N/A	-			Apenas	Apenas no WFS	
Farmácia Lima Coutinho	41.2252318245	-8.61137288226	Lima Coutinho	10.25	41.2252511	-8.6114922	Farmácia Lima	6.36	41.2252889	-8.6113668	Total	Match Perfeito (3 Fontes)	
Farmácia Central de Catassol	41.2250433700	-8.61552115952	Farmácia Centra	8.63	41.2250589	-8.6154201	Farmácia Centre	9.59	41.225076	-8.615415	Total	Match Perfeito (3 Fontes)	
Farmácia Bastos	41.2182859238	-8.60359468281	Farmácia Bastos	5.17	41.2182427	-8.6035718	Farmácia Bastos	4.61	41.2182445	-8.6035932	Total	Match Perfeito (3 Fontes)	
Farmácia Agra	41.2140724845	-8.59462168487	N/A	-			Farmácia Agra	5.28	41.2140433	-8.5945719	Parcial	Match Parcial (2 Fontes)	
Farmácia Eugénia	41.1858744429	-8.58498396172	N/A	-			Farmácia Eugén	11.18	41.1859376	-8.58488	Parcial	Match Parcial (2 Fontes)	
Farmácia Martins da Costa	41.2041353447	-8.57077948878	Farmácia Martin	1.03	41.204143	-8.5707864	Farmácia Martin	21.24	41.2039489	-8.5707245	Total	Match Perfeito (3 Fontes)	
Farmácia das Guardieiras	41.2513972260	-8.65069548498	N/A	-			Farmácia das Gi	10.11	41.2513913	-8.6508162	Parcial	Match Parcial (2 Fontes)	
Farmácia Bom Despacho	41.2331407361	-8.6233342169	Farmácia Bom C	11.77	41.2331115	-8.6234687	Farmácia Bom C	9.00	41.2331738	-8.6234316	Total	Match Perfeito (3 Fontes)	
Farmácia Álvaro Agente	41.2363599598	-8.61583106077	N/A	-			Farmácia Nova	12.78	41.2364349	-8.6159469	Parcial	Match Parcial (2 Fontes)	
Farmácia do Castelo	41.2622990250	-8.61570162615	Farmácia do Cai	2.38	41.2623201	-8.6156968	Farmácia do Cai	6.46	41.2623544260	-8.61572495373	Total	Match Perfeito (3 Fontes)	
Farmácia Aliança	41.2420086534	-8.60858416659	Farmácia Alianc	22.13	41.241915	-8.6088177	Farmácia Alianc	2.12	41.2420274	-8.6085888	Total	Match Perfeito (3 Fontes)	
Farmácia de Silva Escura	41.2555752168	-8.59139434967	N/A	-			Farmácia de Silv	4.28	41.2555377	-8.5914057	Parcial	Match Parcial (2 Fontes)	
Farmácia Araújo	41.2295046898	-8.58796795717	N/A	-			Farmácia Araújo	8.29	41.2294657	-8.5880524	Parcial	Match Parcial (2 Fontes)	
Farmácia da Maia	41.2065802057	-8.56713561815	Farmácia da Ma	9.30	41.2065185	-8.5670605	Farmácia da Ma	5.35	41.2065441	-8.5671778	Total	Match Perfeito (3 Fontes)	
Farmácia Mendonça	41.2559714920	-8.54610940364	N/A	-			Farmácia Mend	14.97	41.2560524	-8.5463326	Parcial	Match Parcial (2 Fontes)	
Farmácia Vales	41.1863003101	-8.59670419395	Farmácia Vales	18.30	41.1861384	-8.5967432	Farmácia Vales	22.58	41.1861047	-8.5967767	Total	Match Perfeito (3 Fontes)	
Farmácia Sousa Torres	41.2194648510	-8.56091887307	Farmácia Sousa	18.17	41.2196247	-8.5608736	N/A	-			Parcial	Match Parcial (2 Fontes)	
Farmácia Moreira Barros	41.2059003915	-8.59730428403	N/A	-			Farmácia Moreir	63.85	41.205397	-8.596937	ConflitoLoc	Conflito Localização (>30m)	[OV] Desvio: 63m
Farmácia Gemunde	41.2671274813	-8.64331532711	Farmácia Gemu	14.81	41.2670618	-8.6431612	Farmácia Gemu	13.84	41.2670079	-8.6432695	Total	Match Perfeito (3 Fontes)	
Hospital de Dia da Maia	41.2348640091	-8.62315161309	Hospital de Dia	19.04	41.2349136	-8.6233695	Hospital de Dia	44.40	41.2346469	-8.6235973	ConflitoLoc	Conflito Localização (>30m)	[OV] Desvio: 44m
Unidade de Saúde Familiar Saúde em l	41.1958052218	-8.57886925837	Unidade de Saú	3.28	41.1958332	-8.5788816	USF Saúde em l	28.90	41.195602	-8.578654	Total	Match Perfeito (3 Fontes)	
Unidade de Saúde Familiar Odisseia	41.2335686930	-8.61703265636	Unidade Local d	1.84	41.2335639	-8.6170116	N/A	-			Parcial	Match Parcial (2 Fontes)	
Unidade de Saúde Familiar Lídador	41.2183186545	-8.60561428919	Unidade de Saú	6.39	41.2182758	-8.6055634	Unidade de Saú	9.35	41.2184019	-8.6056304	Total	Match Perfeito (3 Fontes)	
Serviço de Atendimento a Situações Ur	41.2331531247	-8.62593682613	N/A	-			SASU Maia	40.13	41.2333593	-8.6263307	ConflitoLoc	Conflito Localização (>30m)	[OV] Desvio: 40m
Unidade de Saúde Nogueira	41.2348679390	-8.58659125907	N/A	-			N/A	-			Apenas	Apenas no WFS	
Unidade de Saúde de Milheiros	41.2183137363	-8.58914272812	UCSP Maia - Mil	32.54	41.2183351	-8.5887547	Unidade de Saú	26.94	41.2183042	-8.5888209	ConflitoLoc	Conflito Localização (>30m)	[OSM] Desvio: 32m

Figura 4: Exemplo da tabela detalhada gerada no Google Sheets, pronta para ser entregue aos técnicos da CMM para validação das discrepâncias.

7. Conclusão

O estágio cumpriu os objetivos propostos, entregando à Câmara Municipal da Maia um conjunto de ferramentas de auditoria de dados robustas e modernas. A evolução técnica do projeto, desde simples scripts até pipelines de *Big Data* com DuckDB e processamento de linguagem natural (Fuzzy Matching), demonstra a complexidade de manter dados consistentes numa Smart City.

As ferramentas desenvolvidas permitem agora à autarquia identificar proativamente erros nos seus dados (WFS/GesEdu) ou desatualizações nas plataformas públicas (OSM), garantindo uma melhor informação ao cidadão.

Trabalho Futuro: Sugere-se a migração destes notebooks para um orquestrador como o Apache Airflow e a criação de uma interface web simples para que os técnicos possam validar as correções sugeridas (“Human-in-the-loop”).

Bibliografia

- [1] Câmara Municipal da Maia, «GeoServer da Câmara Municipal da Maia». [Em linha]. Disponível em: <https://geoserver.cm-maia.pt/geoserver/web/>
- [2] A. Mobasher, A. Zipf, e L. Francis, «Multisource spatial data integration for use cases applications», *Transactions in GIS*, vol. 21, 2017, doi: 10.1111/tgis.12987.
- [3] P. Neis, D. Zielstra, e A. Zipf, «Completeness of OpenStreetMap data: The case of Germany», *ISPRS Int. Journal of Geo-Information*, vol. 1, pp. 6–25, 2011.
- [4] L. Foundation, «Overture Maps Foundation Data Schema». [Em linha]. Disponível em: <https://overturemaps.org/download/>
- [5] Câmara Municipal da Maia, «Guia de Recursos Sociais do Município da Maia». 2025. [Em linha]. Disponível em: https://www.cm-maia.pt/cm-maia/uploads/writer_file/document/13110/guia_de_recursos_sociais_do_municipio_da_maia.pdf
- [6] S. J. Rey, D. Arribas-Bel, e L. J. Wolf, *Geographic Data Science with Python*. CRC Press, 2023. [Em linha]. Disponível em: <https://geographicdata.science/book/>
- [7] V. I. Levenshtein, «Binary codes capable of correcting deletions, insertions, and reversals», *Soviet physics doklady*, vol. 10, pp. 707–710, 1966.
- [8] R. Niranjana, «Proximity Analysis using Python». [Em linha]. Disponível em: <https://medium.com/geekculture/proximity-analysis-using-python-ffd16c457f19>
- [9] N. R. Chopde e M. Nichat, «Landmark based shortest path detection by using A* and Haversine formula», *Int. Journal of Innovative Research in Computer and Communication Engineering*, vol. 1, pp. 298–302, 2013.

8. Apêndices

8.1. A. Repositório, Notebooks e Dados

Todos os recursos desenvolvidos e resultados gerados estão acessíveis através dos seguintes links:

8.1.1. Código Fonte

- **Repositório GitHub (Documentação e Scripts):**

<https://github.com/RodrigoMendes04/PI2025-DataHarmonization.git>

8.1.2. Pipelines de Processamento (Google Colab)

- **Pipeline Metro:** <https://colab.research.google.com/drive/1Rc1AaOzQSwrWFVJWQzomUrCGvJRFgbv0>
- **Pipeline Escolas:** https://colab.research.google.com/drive/1_3f4ehdsPWR4VvbbyKHswYmWWWTh1hbN
- **Pipeline Serviços Sociais:** <https://colab.research.google.com/drive/1sPljxaxvR1Pw0InJGZKBcuBGRd7SRUKT>
- **Pipeline Saúde:** https://colab.research.google.com/drive/10WhQz96-SIWJM2vEG5ji-ew0q_f-ZoRd
- **Pipeline Autocarros:** <https://colab.research.google.com/drive/1RJObbbVQfazrcErgpMcXdMYDfS8itqwg>
- **Pipeline Rios e Ribeiras:** <https://colab.research.google.com/drive/1gIuS3VzeZxJndUG8QBLgqZP2p7gn1hKP>

8.1.3. Relatórios de Resultados (Google Sheets)

- **Resultados Metro:** <https://docs.google.com/spreadsheets/d/117rBWVezidc33NpGOHieUssKAQG63LJBbZfGKm3ocac>
- **Resultados Escolas:** https://docs.google.com/spreadsheets/d/1MuL7dj7H1m5g4YovFih_dagAIOwx4UoSQuWJMee5LKc
- **Resultados Serviços Sociais:** <https://docs.google.com/spreadsheets/d/1FkuzSo4WoUqB5iechWalDWnoZFsFo-VLrBw9cCEsXbQ>
- **Resultados Saúde:** <https://docs.google.com/spreadsheets/d/1Vsu8eSSrsfjM9Hk7fWETqs1NlovwDGsi-rEBKN3fLr0>
- **Resultados Autocarros:** https://docs.google.com/spreadsheets/d/1cbbg2NcfwPGyWBqmfMAILyal42XrKfOPirU_JasOUJo
- **Resultados Rios:** <https://docs.google.com/spreadsheets/d/1CsJw8c1aKnbpRBOTRZMYQ0w8CeJeLQUp3oU73d-FPk>

8.1.4. Fontes de Dados Externas

- **OpenStreetMap (API Overpass):** <https://overpass-api.de/>
- **Overture Maps (AWS S3):** <https://overturemaps.org/> (Bucket: `s3://overturemaps-us-west-2/`)
- **Plataforma GesEdu (CMM):** <https://www.gesedu.pt/PesquisaRede>

8.2. B. Scripts e Soluções Técnicas

8.2.1. B.1 Tratamento de Erro de Segurança (GTFS Error 403)

Solução de **fallback** implementada para contornar o bloqueio do servidor do Metro do Porto aos IPs do Google Colab.


```
def load_gtfs_safe(url, local_path):
    try:
        # Tenta download direto
        response = requests.get(url, timeout=10)
        response.raise_for_status()
        return process_gtfs(response.content)
    except requests.exceptions.HTTPError as e:
        if e.response.status_code == 403:
            print("Erro 403 detetado. A usar ficheiro local de backup...")
            if os.path.exists(local_path):
                return process_gtfs_local(local_path)
            else:
                raise Exception("Backup local não encontrado.")
```

8.2.2. B.2 Código do Diagrama de Arquitetura

O diagrama da Figura 1 foi gerado utilizando a ferramenta Mermaid.ai com o seguinte código fonte:

```
---
config:
  layout: dagre
---
graph TD
    classDef fontes fill:#elf5fe,stroke:#01579b,stroke-width:2px,color:black;
    classDef process fill:#e8f5e9,stroke:#2e7d32,stroke-width:2px,color:black;
    classDef output fill:#fff3e0,stroke:#ef6c00,stroke-width:2px,color:black;

    subgraph Sources ["1. Fontes de Dados"]
        direction TB
        WFS["WFS Maia<br/>(Oficial)"]:::fontes
        OSM["OpenStreetMap<br/>(API Overpass)"]:::fontes
        GTFS["GTFS / PDF<br/>(Ficheiros)"]:::fontes
        OV["Overture Maps<br/>(AWS S3 / Parquet)"]:::fontes
    end

    subgraph Python ["2. Processamento"]
        direction TB
        Ingest["Ingestão & Limpeza<br/>(DuckDB / Pandas)"]:::process
        Norm["Normalização &<br/>Filtragem Espacial"]:::process

        subgraph Logic ["Núcleo de Reconciliação"]
            direction TB
            Dist["Cálculo Distância<br/>(Haversine)"]:::process
            Fuzzy["Comparação Nomes<br/>(Levenshtein)"]:::process
            Class["Classificação<br/>(Match/Conflito)"]:::process
        end
    end

    subgraph Results ["3. Outputs"]
        direction TB
        XLS["Relatório<br/>Google Sheets"]:::output
        MAP["Mapa Interativo<br/>Folium HTML"]:::output
        MAIL["Notificação<br/>Email SMTP"]:::output
    end
```

```
end

WFS --> Ingest
OSM --> Ingest
GTFS --> Ingest
OV --> Ingest

Ingest --> Norm
Norm --> Dist
Norm --> Fuzzy

Dist --> Class
Fuzzy --> Class

Class --> XLS
Class --> MAP
XLS --> MAIL
```